



ESCUELA POLITÉCNICA NACIONAL



FACULTAD DE INGENIERÍA DE SISTEMAS

INGENIERÍA DE COMPUTACION

PERÍODO ACADÉMICO: 2025-B

ASIGNATURA: ICCD412 Métodos Numéricos

GRUPO: GR1CC

TIPO DE INSTRUMENTO: *Actividad Extracurricular 6b*

FECHA DE ENTREGA LÍMITE: [28/01/2026]

ALUMNO: *Kevin Eduardo Garcia Rodríguez*

TEMA

- Redes Neuronales

OBJETIVOS

- Investigue sobre el uso de factorización de matrices en la arquitectura de redes neuronales

DESARROLLO:

Uso del factorización de matrices en la arquitectura Transformer

El factorización de matrices en la arquitectura de redes neuronales Transformer se utiliza principalmente para optimizar el uso de memoria, reducir el costo computacional y mejorar la eficiencia del entrenamiento y la inferencia. Esta técnica consiste en descomponer una matriz grande en el producto de dos o más matrices de menor dimensión.

En los Transformers, el factorización de matrices se aplica especialmente en:

- Las matrices de proyección de los mecanismos de autoatención (Query, Key y Value).
- Las capas Feed-Forward (FFN).
- Técnicas modernas como Low-Rank Approximation, Matrix Factorization y Parameter Sharing.

Razones para realizar factorización de matrices en Transformers

1. Reducción del número de parámetros

Las matrices de gran tamaño pueden descomponerse en matrices de menor rango, disminuyendo significativamente la cantidad total de parámetros del modelo.

2. Disminución del costo computacional

El cálculo de productos entre matrices factorizadas requiere menos operaciones aritméticas, lo que reduce el tiempo de entrenamiento y de inferencia.

3. Optimización del uso de memoria

Al almacenar matrices más pequeñas, se reduce el consumo de memoria RAM y VRAM, facilitando la ejecución del modelo en hardware limitado.

4. Escalabilidad del modelo

Permite entrenar modelos Transformer más grandes sin un crecimiento proporcional del costo computacional.

5. Regularización implícita

El uso de aproximaciones de bajo rango limita la complejidad del modelo, ayudando a reducir el sobreajuste.

Ventajas del factorización de matrices en la arquitectura Transformer

- **Mayor eficiencia energética**, especialmente importante en modelos de gran escala.
- **Aceleración del entrenamiento y la inferencia.**
- **Posibilidad de despliegue en dispositivos con recursos limitados.**
- **Mejor relación rendimiento–costo**, manteniendo una precisión competitiva.
- **Facilidad para aplicar compresión de modelos** sin rediseñar la arquitectura base.

Conclusión

El factorización de matrices es una técnica clave en la optimización de la arquitectura Transformer, ya que permite reducir la complejidad computacional y el número de parámetros sin sacrificar significativamente el rendimiento del modelo. Gracias a estas ventajas, es ampliamente utilizado en Transformers modernos y en modelos de lenguaje a gran escala.

REFERENCIAS

- [1] Amazon Web Services (AWS), “¿Qué son los transformadores en la inteligencia artificial?,” AWS. [En línea]. Disponible: <https://aws.amazon.com/es/what-is/transformers-in-artificial-intelligence/>. [Accedido: 26 Ene. 2026]. ([Amazon Web Services, Inc.](#))
- [2] Codificando Bits, “Redes Transformer,” CodificandoBits.com. [En línea]. Disponible: <https://codificandobits.com/blog/redes-transformer/>. [Accedido: 26 Ene. 2026]. ([Codificando Bits](#))
- [3] DeepAI, “Transformer Neural Network Definition,” DeepAI. [En línea]. Disponible: https://deepai.org/machine-learning-glossary-and-terms/transformer-neural-network? x_tr_sl=en& x_tr_tl=es& x_tr_hl=es& x_tr_pto=tc. [Accedido: 26 Ene. 2026]. ([deepai.org](#))